

Mechanistic Interpretability : 解釈可能性研究の新たな潮流

Mechanistic Interpretability: A New Trend in Interpretability Research

青木 洸士郎
Koshiro Aoki

早稲田大学
Waseda University
aokikoshiro@akane.waseda.jp

高槻 瞭大
Ryota Takatsuki

サセックス大学, AI アライメントネットワーク
University of Sussex / AI Alignment Network
R.Takatsuki@sussex.ac.uk

峰岸 剛基
Gouki Minegishi

東京大学
The University of Tokyo
minegishi@weblab.t.u-tokyo.ac.jp

趙 羽風
Hakaze Cho

理化学研究所, 東北大学
RIKEN / Tohoku University
yufeng.zhao@riken.jp

Keywords: mechanistic interpretability, interpretability, explainability, AI alignment.

Summary

Mechanistic Interpretability (MI), originating from traditional interpretability which tracks the reasons behind neural network behaviors, dedicates itself to reconstructing neural network models into human-understandable algorithms, often expressible as pseudocode or referred to as circuits. MI typically attributes each step in the pseudocode to specific model modules, thereby accomplishing a semantic decomposition of the neural network model. This methodology is particularly effective for large models and has thus risen in prominence with the emergence of large language models, attracting growing attention from the perspectives of AI safety and reliability. However, this field's rapid growth has led researchers to adopt disparate concepts and methods, resulting in a lack of a unified framework. Moreover, the precise meaning of “mechanistic” remains ambiguous, and the distinction between MI and existing interpretability methods has yet to be clearly established. In this paper, we first survey the historical and cultural background of MI, clarify its differences from traditional interpretability approaches, and propose a conceptual framework that organizes key ideas in MI. Additionally, we discuss MI methods and their limitations, ranging from observational to interventional approaches. Finally, we explore current challenges in MI research and offer directions for future work to understand increasingly complex AI systems and ensure their safety.

1. はじめに

近年, 大規模言語モデル (LLM) をはじめとするディープニューラルネットワークは飛躍的に性能を向上させているが, そこで実現されるアルゴリズム的な計算過程や内部メカニズムはブラックボックス^{*1}であり, 解釈可能性が問題視されている [Adebayo 18, Bilodeau 22, Kindermans 19]. ニューラルネットワークの解釈可能性に関する研究は, 勾配ベースの顕著性マップやプロービング, 注意機構

の分析などを通じて行われてきた [Jain 19, Simonyan 13, Tenney 19]. こうした研究の蓄積を背景に, **Mechanistic Interpretability (MI)** は, 学習済みニューラルネットワークをリバースエンジニアリングし, 内部で実行される計算を人間が理解可能なアルゴリズムとして記述することを目指す新興分野として注目を集めている [Bereska 24, Rai 24, Sharkey 25, Wiegrefe 24]. MI は, モデルの入出力関係だけでなく内部の因果構造, すなわちモデルを構成する部分の因果的な相互作用を解明することを中心的な理念とする.

^{*1} アーキテクチャもパラメータもわかっていて行列演算の数式として明示的に記述できるという意味では「ホワイトボックス」であるが, ここでの「ブラックボックス」は, ニューラルネットワークがどのような表現を形成し, その表現のもとで具体的にどのような手続きを実行しているかという表現・アルゴリズムレベル [Marr 10] の理解が不十分であるという意味である.

大規模言語モデルの発展に伴って MI は急速に発展しているものの, 研究者によって独自の概念や手法が提案されており, 統一的な枠組みが不足している. また, “Mech-

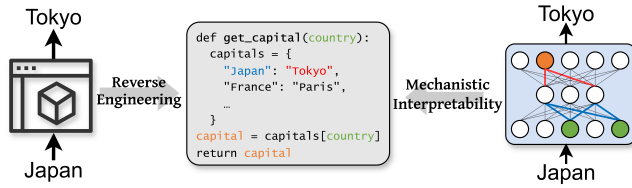


図 1 Mechanistic Interpretability の概念図 (左) とコンピュータプログラムとのアナロジー [Olah 22] (右)

anistic” という用語自体の定義が曖昧で、既存の解釈可能性手法との位置付けが十分に整理されていない。こうした状況は、MI の成果を体系的に比較・評価し、その応用範囲を適切に理解するうえで大きな障壁となっている。そこで本論文は、MI 研究の全体像を捉え直し、今後の発展に向けた議論の基盤を提供する。既存のサーベイ論文では、MI の歴史的・文化的背景 [Wiegrefe 24], AI の安全性との関連 [Bereska 24], 技術的手法 [Rai 24], 未解決問題 [Sharkey 25] といった個別の観点から MI がまとめられている。本論文ではこれらの観点を踏まえつつ、産業動向を含む研究の実用化に向けた文脈についても整理する。こうした実践的な動向は、MI 研究の現在地と今後の方向性を理解するうえで重要である。そのうえで、MI が直面する技術的課題のうち、大規模モデルへのスケーラビリティ、分析手法の自動化、原理的限界に焦点を当てて議論する。

本論文ではまず、MI が形成されてきた歴史的・文化的背景を概観し (2 章)、既存の解釈可能性手法との比較を通じて MI の位置づけを明確化したうえで、その概念的枠組みを整理する (3 章)。続いて、MI で用いられる代表的な手法を解説し (4 章)、実際の応用事例を紹介する (5 章)。さらに、MI が抱える課題や未解決の問題を提示し (6 章)、複雑化が進む AI システムの理解と安全性確保のために今後どのような研究が必要かを展望する (7 章)。

2. 背景

2.1 Mechanistic Interpretability の定義

まず、MI とは何かについて説明する。多くの研究では MI は次のように説明される [Bereska 24, Elhage 21, Olah 22]。

バイナリコードをプログラマーが読めるソースコードにリバースエンジニアリングするのと同じように、ニューラルネットワークによって実行される計算をリバースエンジニアリングして擬似コードに変換すること。

言い換えれば、事前に学習しておいたコネクショニズムのモデル (ニューラルネットワーク) を、事後的に記号主義のモデル (擬似コード) へと変換することともいえる。そのため、MI ではしばしば、コンピュータプログラムのアナロジーを用いてニューラルネットワークを解釈

することがある (図 1)。

MI における “Mechanistic” には、科学哲学における機械論 (Mechanism) の持つ「複雑な現象を、それを構成する部分の因果的な相互作用として理解する」という意味合いが含まれている [Craver 25]。ただし、最も基本的で単一のレベルの要素から現象を説明しようとする還元論を必ずしも含意するわけではない。実際、MI ではニューロンレベル [Gurnee 24] や注意ヘッドレベル [Zheng 25]、特徴量レベル [Huben 24b] など、異なるレベルからの階層的な説明がなされている。

ただし、“Mechanistic Interpretability” という用語は多義的であり、その指示対象は研究者や文脈によって異なる。Wiegrefe ら [Wiegrefe 24] は、この用語の使われ方を次の四つに整理している。(1) モデル内部の中間表現における因果メカニズムの解明を要求する狭義の技術的定義。(2) 活性値や重みを含むモデル内部の検査全般を指す広義の技術的定義。(3) MI コミュニティに由来する研究を指す狭義の文化的定義。(4) AI 解釈可能性研究全般を包含する広義の文化的定義。

本論文では、MI を上記の第一の定義、すなわちモデル内部の因果メカニズムの解明を志向する研究として位置づける。ただし、因果的検証を直接含まない手法であっても、因果メカニズムの発見や検証を目的とする研究の過程で用いられるものは、MI 研究の方法論の一部として扱う。因果的検証が MI の中核的な目標であるとしても、その前段階として内部表現の観察や特徴量の同定は不可欠だからである。例えば、スパースオートエンコーダ (SAE) [Bricken 23, Huben 24a] による特徴量抽出、Logit Lens [nostalgebr 20] による内部表現のデコード、内部表現の幾何学的分析などがこれに該当する。こうした手法の多くは、MI という用語が登場する以前から解釈可能性研究で用いられてきたものである。これらの手法は、それ単体では MI の狭義の技術的定義を満たさないが、因果的検証と組み合わせられることで MI 研究の構成要素となりうる。本論文が手法を紹介する際に扱う範囲は、この立場に基づいている。

2.2 Mechanistic Interpretability の歴史

Mechanistic Interpretability という用語が定着する以前から、ニューラルネットワークの内部メカニズムを理解しようとする試みは存在していた。初期には LSTM の個別ユニットが長距離の構造的特徴を追跡することが示され [Karpathy 15]、表現の一部を消去して予測への影響

表 1 既存の解釈性と MI の比較

	行動主義的 (Behavioral)	帰属的 (Attribution)	概念ベース (Concept)	機械論的 (Mechanistic)
主な分析単位	入出力の振る舞い	特徴量の貢献度	概念・表現方向	特徴量・回路
代表手法	SHAP [Lundberg 17]	Grad-CAM [Selvaraju 17]	線形プロープ [Alain 17]	SAE [Huben 24a]
目的	入出力関係を評価	特徴量の影響の可視化	概念の読み出し	因果特定・制御性向上

を測る手法が提案された [Li 16]. ニューラル機械翻訳や BERT の内部表現を層ごとに探索するプロービングの研究では、言語情報が層間で段階的に変化することが明らかにされた [Belinkov 17, Shi 16, Tenney 19]. 一方、プローブがモデルの表現内容ではなくタスク自体を学習する危険性も指摘され、対照条件の必要性が論じられた [Hewitt 19]. 注意機構についても、その説明としての忠実性が疑問視され [Jain 19, Wiegrefe 19], 注意重みへの介入実験 [Serrano 19] やヘッドごとの機能特化の分析 [Voita 19] が進んだ. これらの研究群は、相関的な可視化から因果的・構成要素単位の介入へという、現代の MI の方法論の基盤を形成した.

こうした自然言語処理における解釈可能性研究が展開される一方で、当時の機械学習研究全体の中心はコンピュータビジョンであり、解釈可能性の主要手法は勾配ベースの顕著性マップ (Saliency Map) [Simonyan 13] であった. 当時信頼性への批判 [Adebayo 18, Kindermans 19] が高まっていた顕著性マップと区別するために、2020 年から 2021 年にかけて OpenAI の研究者らによって投稿されたブログ「Circuits Thread [Cammarata 20]」で Mechanistic Interpretability という用語が初めて公に使用された. MI 黎明期は、畳み込みニューラルネットワークにおいて、フィルタやニューロンが検出している模様、エッジ、パーツなどを可視化し、それらがどのように合成されて最終的な出力に至っているのかをボトムアップに把握することが主眼であった [Olah 20b].

近年の LLM の台頭に伴い、MI の研究対象の中心も次第に自然言語処理へと移行した. Circuits Thread の後継であり、2021 年から始まったブログ「Transformer Circuits Thread^{*2}」では、視覚モデルではなく言語モデル (特に LLM) へと対象を切り替えた [Elhage 21]. MI はモデルを構成要素に分解して理解を目指すため、大規模なモデルの解釈と相性が良く、このことも研究対象が LLM へ移行した一因である. 結果として、現在の MI 研究の多くはトランスフォーマーベースの LLM を対象としている [Rai 24].

2.3 Mechanistic Interpretability に関する産業動向

AI の安全性やアライメント (価値観の整合) に関する議論の中で、モデルの挙動をブラックボックスのまま信用することへの懸念が LLM の性能向上によって強まっ

た. その結果、MI は AI の安全性のための技術として、Anthropic [Anthropic] や Google DeepMind [Nanda 24], OpenAI [Gao 25] などの現在の主要な AI 企業が定期的に研究を発表している. 中でも Anthropic は、LLM を開発する際に、欺瞞などの特定の特徴量を監視することでミスアライメントを検知したり、安全性を評価したりするための実務的な手段として MI の手法を実際に活用している [Anthropic 25a, Anthropic 25b, Anthropic 26]. 海外では MI に特化したスタートアップが増加しており、LLM の挙動を透明化するためのサービス開発や研究が活発化している [apollo, conjecture, goodfireGo, tilde]. このように、MI は学術的探究を超えて、LLM の発展とともに産業的にも需要と影響を拡大しつつある.

2.4 既存の解釈可能性との違い

本節では、既存の解釈可能性手法と MI の相違点を整理する (表 1).

LIME [Ribeiro 16] や SHAP [Lundberg 17] などの行動主義的解釈可能性 (Behavioral Interpretability) は、モデルをブラックボックスとして扱い、入力と出力の対応関係に注目する. 同様に、顕著性マップ [Simonyan 13] や統合勾配 (Integrated Gradients) [Selvaraju 17, Sundararajan 17] などの勾配に基づく帰属的手法 (Attribution Methods) は、入力特徴量の寄与度を定量化するが、モデル内部のアルゴリズムを明らかにするものではない. また、プロービング [Alain 17] などの概念ベースの解釈可能性 (Concept-Based Interpretability) [Zou 23] は、モデル内部で抽象概念がどう表現されるかをトップダウンに調査するものの、それだけではそれらの概念がモデルのどのような因果構造の一部として実装されているかについては言及できない. なお、本稿で扱う観点では、説明可能 AI (Explainable AI; XAI) と呼ばれる手法群は概ね行動主義的・帰属的・概念ベースの手法に整理できる.

これに対し、MI はモデル内部の因果構造やメカニズムの解明を志向する点で、他の解釈可能性手法と異なる. ただし、2.1 節で述べたように、MI と既存の解釈可能性の境界は明確に画定できるものではない [Wiegrefe 24]. 個々の手法のレベルでは、MI と既存の解釈可能性は多くの方法論を共有している. 例えば、プロービングは概念ベースの解釈可能性の代表的手法であるが、プロービングで特定した表現に対して因果的介入を行い、その表現がモデルの出力にどう寄与するかを検証する研究も存

^{*2} <https://transformer-circuits.pub/>

在する [Elazar 21, Giulianelli 18]. 同様に, SAE で抽出された特徴量が MI として意味を持つためには, 回路発見や因果的検証を通じて, モデルの因果メカニズムの一部として位置づけられることが求められる [Mueller 25]. すなわち, 両者を分けるのは個々の手法そのものではなく, 因果メカニズムの解明を最終的な目標とするかどうかという研究分野全体の志向性である.

こうした技術的な類似性にもかかわらず, MI の文化的な特徴は他の解釈可能性コミュニティとの差異を生み出している. MI はアライメントコミュニティとのつながりが強く, 研究成果が LessWrong^{*3}や AI Alignment Forum^{*4}などのブログやオープンなプラットフォームで共有されることが多い [Anthropic, Cammarata 20]. Wiegrefe ら [Wiegrefe 24] が指摘するように, MI という用語は技術的な定義と並行して, このコミュニティに由来する研究を指す文化的な意味合いも有している.

また, MI の文脈から派生した関連分野として, Developmental Interpretability [Hoogland 23] がある. この分野では主に特異学習理論 [Watanabe 09] を用いてニューラルネットワークの学習ダイナミクスを解釈する.

3. 基本概念

MI の中心的な概念として, **特徴量 (Features)**, **回路 (Circuits)**, **普遍性 (Universality)**, **重ね合わせ (Superposition)**, **多義性 (Polysemanticity)** などがある. MI の創始者とされる Chris Olah は, 特徴量はニューラルネットワークの基本単位であり, それらが重みによってつながり回路をなし, 特徴量や回路にはモデルやタスクを超えた普遍性がある, と主張をしている [Olah 20b].

特徴量とは, モデルの入力に内在するパターンであり, モデルの解釈の基本単位とされる. 特徴量はモデルの表現空間の方向に対応するという線形表現仮説 [Elhage 22, Park 24a] が有力であるが, 議論の余地がある [Black 22, Engels 25a].

回路とは, モデルの内部において, ある特徴量の集合を入力として, 後続のある特徴量の集合を出力とするサブネットワークである. 実用的には, モデルがあるタスクを解くための必要十分なサブネットワークを指し, さまざまな回路が発見されている [Cammarata 21, Hanna 23, Schubert 21, Wang 23].

普遍性は, ニューラルネットワークの特徴量や回路はタスクやアーキテクチャを超えて類似するという仮説である (共通する回路パターンはモチーフと呼ばれる). これは, 特定のモデルの解釈が他のモデルの解釈にも役立つことを意味し, 多くの MI 研究の存在意義に関わる. 異なる初期値 [Gurnee 24], 異なるトランスフォーマーモデル [Merullo 24], 異なるアーキテクチャ [Wang 25] 間で

表 2 Mechanistic Interpretability に関する用語とその和訳

English Term	和訳
Activation	活性値
Attribution	帰属
Circuit	回路
Feature	特徴量
Induction Head	帰納ヘッド
Mechanistic Interpretability	機械論的解釈可能性
Monosemanticity	単義性
Polysemanticity	多義性
Residual Stream	残差ストリーム
Superposition	重ね合わせ
Universality	普遍性

普遍性の証拠が集まってきている.

重ね合わせ仮説は, 線形表現仮説を前提とし, モデルが表現空間の次元数よりも多くの特徴量を表現するために, ほぼ直交する基底を利用しているとするものである [Elhage 22]. このような基底の数は, 直交基底の数に対して指数的に増えることが知られている. この仮説が唱えられた背景として, 初期の MI およびそれ以前の解釈可能性の研究では, ニューロンを解釈の単位として, 各ニューロンに対応する特徴量を可視化していた [Nguyen 19, Olah 17]. しかし, 次第にニューロンはしばしば**多義的 (Polysemantic)**であること, つまり一見関係のない複数の特徴量に同じニューロンが反応することが明らかになってきた. 解釈を容易にするために, **スパースオートエンコーダ (SAE)**を用いてより**単義的 (Monosemantic)**な特徴量方向を求める方法論が確立されてきている [Bricken 23, Huben 24a].

3.1 用語の和訳

MI は新興分野であるため, 関連用語の和訳に揺れが生じている状況にある. この不統一は分野の発展を阻害しかねないため, 表 2 では, MI でよく用いられる英語の用語について, すでに慣例となっている和訳も考慮しながら本来の意味を反映していると考えた和訳を提供する.

「Mechanistic Interpretability」はしばしば「**機構的**解釈可能性」と訳されることもあるが, 2.1 節で述べたように, MI が機械論 (Mechanism) を含意する点で, 我々は「**機械論的**解釈可能性」の方がより自然な和訳だと考える.

4. 手法

MI では, モデルの内部に自在にアクセス・介入できる利点を活かして, その内部メカニズムを明らかにすることを目的としたさまざまな手法が提案されてきた (図 2). 本章で紹介する手法には, MI という用語が登場する以前から解釈可能性研究で用いられてきたものも含ま

*3 <https://www.lesswrong.com/>

*4 <https://www.alignmentforum.org/>




図 2 Mechanistic Interpretability で用いられる主な手法

れる。2.1 節で述べたように、本論文ではこれらの手法を、因果メカニズムの解明という目標に向けた研究過程で用いられる MI の方法論の一部として位置づける。

4.1 特徴量・内部表現測定

特徴量およびそれを内包する内部表現は、LLM 内部におけるモジュール間の情報通信経路であり、同時に各モジュールの作用結果を保持する役割を担っている。したがって、MI の主要な研究対象が特定の機能をもつモジュールであるとしても、特徴量の性質を推論の時系列（すなわちネットワーク層系列）に沿って測定することは、これらのダイナミクスを生み出す特異なメカニズムの存在を示唆、あるいは共変的 (Covariant) に裏付ける可能性が高い。内部メカニズムの存在を示唆する仮説を生成し、後続の因果的検証 (4.3 節) に先立つ探索的分析として機能する点で、これらの手法は MI 研究の過程において重要な役割を果たしている。現時点で、この目的のために以下のような測定手法が開発されている。

§ 1 特徴量幾何学

測度空間上のベクトルとして、一部の研究は内部表現およびそれに内包される特徴量の幾何学的性質を定量的に解析している。単一の点自体には特別な幾何学的性質は存在しないため、この種の研究は主として特定の入力集合から導かれる内部表現集合を対象としている。

有効次元数・偏心率 [Ansuini 19, Cho 26, Ethayarajh 19, Kataiwa 25, Yang 25]. 内部表現の幾何的特性を定量化する代表的な手法として、有効次元とコサイン類似度、偏心率がある。有効次元は、ある精度のもとで内部表現集合を表現するために必要な最小の座標数を測定する手法であり、多様体に基づく研究 [Ansuini 19, Kataiwa 25] では、

例えば三次元空間上の球面上の点が二つの座標で表現できるように、内部表現がより低次元の多様体上に存在するかを評価する。一方で、線形空間に基づく手法 [Yang 25] では、線形空間中で実際に利用されている（すなわち十分な共分散や固有値を持つ）直交ベクトルの数を探索し、これを有効ランク [Roy 07] と呼ぶ。有効次元の測定は、特徴量の単義性や内部表現中のチャンネル利用率を示唆する。また、内部表現点群の集中度を測るコサイン類似度や偏心率がある。これらは異なる点間の平均コサイン類似度やユークリッド距離上の偏心率によって計算され、特徴量の単義性や単純性を示唆する点で有効次元と共通している。ただし、これらの測定は完全に線形であるため、非線形構造よりも、線形操作が豊富な注意層や語彙射影 (Unembedding) 層の性質をより強く反映すると考えられる。

クラスタ可分性 [Kirsanov 25, Yang 25]. LLM の内部表現は意味に応じてクラスタ化する傾向がある。例えば、ポジティブ文とネガティブ文から得られる内部表現の点群は明確に分離される。この可分性は、LLM が意味属性を正しく符号化し出力できるかどうかを示す指標であり、下流タスク性能とも強く関係する。さらに、アライメントによる応答拒否や特定言語での出力など、LLM の挙動も内部表現上のクラスタ構造として現れることが指摘されている [Huang 25]。

外部特徴量アライメント [Huh 24]. 一部の研究は、LLM の特徴量によって形成される測度空間が外部の実際の意味空間と整合していることを指摘している [Engels 25a, Kadlčík 25, Modell 25]. 簡単な例として、色を表すさまざまな入力 LLM 内部で生成する表現の分布が色相環の構造に従うことが挙げられる [Engels 25a, Modell 25]。




図3 SAE の訓練および特徴量解釈の模式図。詳細は 4.1 節 §2 を参照。

このような整合の強さを評価するために、特徴量アライメント (Feature Alignment) と呼ばれる手法 [Klabunde 25a, Klabunde 25b, Kornblith 19] が提案されており、これらを用いることで LLM が生成する特徴量の質を検証することができる。

§2 重ね合わせの解消

3 章で述べたように、LLM の内部表現は複数の単義的な特徴量が重なり合って構成されていると考えられている [Elhage 22]。したがって、これらの特徴量を解きほぐす (Disentangle) ことは、内部表現の持つ意味を理解するうえで有益である。この手法は本質的に、隠れ空間内で特定の方向を抽出することを目的としており (重ね合わせのため、そのような方向の総数は通常隠れ空間の次元数を上回る)、各方向は特定の概念に対応する。この考え方は、潜在空間内で「語彙」を探索することに類似しており、この種の手法は辞書学習 (Dictionary Learning) [Aharon 06, Shu 25] とも呼ばれる。

スパース仮定に基づき、すなわち一つの内部表現の中で活性化される単義的特徴量は少数に限られるという前提のもとで、スパースオートエンコーダ (Sparse Autoencoder, SAE) [Bricken 23, Gao 25, Huben 24b, Templeton 24] が提案された。図 3 のように、このモデルは二つの線形層から構成され、内部表現を入力してそれを再構成するように学習される。この際、第 1 層の活性化値に L1 正則化を課すことで、上述のスパース性を促進する。この層の活性化値は辞書項目 (Dictionary Entry) の活性化強度として解釈される。また、第 2 層のパラメータは「辞書」と呼ばれ、内部表現集合を再構成するために必要な単義的特徴量を保持する。

同時に、これらの単義的特徴量の意味を自動的に解釈する手法もいくつか提案されている [Bills 23, Cho 25b, Paulo 25]。それらの多くは特定の辞書項目が活性化された際に対応する元のトークン入力に基づいて間接的な解釈を行う。これらの手法は単義的特徴量の数値的表現そのものには直接アクセスしないため、この点が欠点となっている。

一部の研究は、SAE において辞書中の項目がデッド特徴量 (Dead Feature) (すなわち、ある項目が常に活性化

されない) や密集特徴量 (Dense Feature) (すなわち、ある項目が過度に頻繁に活性化される) といった問題を引き起こすことを指摘している。このような現象は SAE のパラメータ効率を損ない、上述したスパース性の原則にも反する。この現象の合理性については一定の説明がなされているものの [Rajamanoharan 24b, Stolfo 25, Sun 25]、多くの研究は依然としてこの現象の除去を目指している。具体的には、第 1 層の活性化関数として、従来の ReLU の代わりに、Gated ReLU [Rajamanoharan 24a] や Top-K [Bussmann 24] などといったスパース性を明示的に促進する活性化関数を用いる手法がある。また、訓練目標を改良し、従来の L1 正則化の代わりに相互情報量損失を導入する研究も存在する [Cho 25b]。

さらに、一部の研究は複雑な訓練入力を使用する。Cross-coder [Lindsey 24] や RouteSAE [Shi 25] のように複数の層の特徴量を統合して SAE の訓練を行う手法がある。また、Transcoder [Dunefsky 24] は MLP 層の入力および出力をそれぞれ SAE の入力と出力として利用している。

一方で、SAE に基づく辞書学習には方法論的な限界も指摘されている。SAE の潜在表現は規模によって変化し、一意で単義的な単位を与えるとは限らない [Leask 25]。また、下流タスクの性能では SAE が既存のベースラインを一貫して改善するとは限らず、解釈手法の下流タスク評価の必要性が指摘されている [Kantamneni 25]。

§3 直接意味デコード

いくつかの研究は、言語モデル (LM) の内部表現の持つ意味をトークンとしてデコードしている。初期の研究 [nostalgebr 20] では、LM の出力層 (正規化と語彙射影行列、すなわち LM ヘッド) を中間層の内部表現 (隠れ状態または残差ストリーム) に直接適用し、Logit Lens として知られる手法を提案した。しかし、LM ヘッドは中間層上で訓練されていないため、分布の不一致が生じる。これを補うため、Tuned Lens [Belrose 23] は線形変換を学習して中間表現を最終層の分布へ写像する。さらに、Patchscopes [Ghandeharioun 24] は内部表現を別の LM に注入し、自動的にデコードを生成する仕組みを採用している。これらの手法はいずれも定量的解析ではなく、内部表現の潜在的特性を定性的に観察するためのもの




図4 文脈内学習を例とした因果推論各方法の模式図。詳細は4.3節を参照。

のである。

4.2 回路発見

上述のような特徴量に対する解析は、確かにいくつかの回路を効果的に発見できるものの、その手法はアドホックかつヒューリスティックであり、必ずしも効率的なものではない。そのため、一部の研究は回路を体系的に発見する方法を提示し、さらに回路内の各接続の強度や各部分が担う機能を明示的に特定しようと試みている。これこそがMIの主要な課題である。

§1 注意スコア

直感的な方法として、各注意ヘッドの注意スコアや、それに基づいて計算された顕著性スコア [Kobayashi 20] を直接観察するという手法がある。これにより、その注意ヘッドが重視する接続の種類を特定し、さらに接続されているトークンを中継点として接続を他の注意ヘッドへと拡張することができる。典型的な例として帰納ヘッド (Induction Head) [Olsson 22] の発見が挙げられる。ここでは、ある中核的なトークン (具体的には文脈内学習タスクにおけるラベルトークン) が二種類の注意ヘッドを中継し、回路を形成している。しかしながら、この方法では複雑な回路を効果的に発見することは難しく、また注意ヘッドに限定されているため、その適用範囲が制限される。さらに、注意スコアが解釈可能性の有効な指標となり得るかどうかについても議論が続いている [Bibál 22]。

§2 自動回路発見

より汎用的な研究では、計算グラフ上で枝刈りを適用し、出力に重要な部分グラフ (すなわち回路) を抽出する手法が提案されている。初期の研究 [Conmy 23] は単純な貪欲法により接続を逐次除去したが、除去のたびに順伝播によるモデルの性能の再評価が必要なため計算コス

トが高かった。これに対し、改良手法 [Syed 23] は1回の順伝播と逆伝播で勾配を用いて全接続の重要度を推定し、効率化を実現した。また、特徴量構成要素の分解によって回路を構築する研究もある。例えば、内部表現の分解を用いる手法 [Hsu 25] や、残差ストリームからSAEで抽出された特徴量をノードとし、逆伝播により接続強度を算出する手法 [Marks 25] が挙げられる。後者ではさらに、SAEの自動特徴量解釈を用いてノードの意味内容を分析することも可能である。最近では、Transcoderを用いてトランスフォーマーのMLPを近似し、近似されたモデル上の特徴間の寄与に基づいて枝刈りされたグラフによって、特定のプロンプトの計算過程を記述する Attribution Graphs と呼ばれる手法も提案されている [Ameisen 25]。得られたグラフは因果メカニズムの仮説として扱われ、介入による追試で検証される [Lindsey 25]。

4.3 因果推論

MIの研究では、求められた回路の因果性、すなわち特定のモデル要素が予測にどの程度寄与しているかを定量的に評価することが求められる。特に、ヒューリスティックな測定手法を用いる場合には注意が必要である。このような場合、得た測定結果 (たとえば特徴量の幾何学的分析の結果) がモデルの出力に直接的な影響を与えているのか、あるいは単なる隠れたメカニズムの副作用にすぎないのかが不明確である。この問題を解決するために、こうした因果性を検証するための方法が提案されている。

§1 ステアリング

ステアリング (Steering) [Turner 23] とは、ある回路の作動メカニズム、特に特定の重要情報をどのように符号化しているかが既知である場合に、その既知の符号化パターンから符号化された情報を編集することで、その回路が出力に対して持つ因果的役割および当該パターン自体の正しさを同時に検証する手法を指す。

一例を図4(2)に示す。「+nタスク」の符号化パターンが既知であれば、「+2タスク」表現を「+5タスク」表現へと変換することが可能であり、これにより当該符号化の信頼性を実証できる。

§2 活性値パッチング

ステアリングの特殊な形態として、活性値パッチング (Activation Patching) [Goldowsky-Dill 23] がある。この手法は、モデル内部の回路を人工的に再構成するものであり、特定の性質を示す入力で活性化された回路の中間計算結果を、その回路を起動しない別の入力へ転写して出力性能の再現を試みる。この転写で出力が良好に再現されれば、その回路が連結し因果的影響を持つことが確認できる。

例えば、図4(3)に示したように、少数事例入力の最後のトークンの隠れ状態をゼロ事例入力の対応トークンの隠れ状態に加算した結果、推論性能が向上するならば、これは該当回路が文脈内学習性能を媒介することを示唆

する。ただし、ステアリングは回路を発見できる場合もあるものの [Meng 22], 多くは走査的・ヒューリスティックな手法であり、通常は自動的な回路発見ではなく、発見済み回路の信頼性検証に用いられる。

§3 アブレーション

図4(4)に示したように、アブレーション (Ablation) ^{*5} は特定の回路の中間もしくは最終的な出力を、入力と無関係な値に固定する。回路を推論過程から除去することでモデルの出力が大きく変化する場合、その回路は出力に対して因果的影響を持つといえる。アブレーションはステアリングと類似した手法であるが、ステアリングが別の推論過程における対応する回路の値を中継するのに対し、アブレーションはむしろ回路が出力する情報そのものを破壊する操作である。

実際の研究では、出力をゼロに固定する方法 [Cho 26] や、入力バッチ上での平均値に固定する方法 [Ghorbani 20] が一般的に用いられる。また、アブレーション後の性能を最大化するよう最適化された固定値を用いる手法 [Li 24] も、合理的な代替案として提案されている。ただし、分布外の極端な破壊は結論を混乱させる可能性がある点には注意が必要である。

5. 応 用 例

これまで、MI の歴史的背景と技術的進展を概観してきた。MI は依然として発展途上の研究分野であるものの、すでに複数の応用事例が報告されており、安全性・効率性・信頼性の観点から AI 研究の新たな潮流を形成しつつある。

5.1 AI 安全性の向上

MI は AI モデルの安全性向上に有力な手段であると考えられる。4 章で述べたような MI ツール群を活用することで、モデル内部における「認知構造」や「推論経路」を可視化し、潜在的な危険挙動や意図しない情報処理を早期に検出できる。具体的には、[Li 23, Meng 22] では、モデル内部に埋め込まれたセンシティブ情報を特定・編集する手法が提案されており、情報漏洩リスクの低減に寄与している。また、[Park 24b] では、潜在的なミスアライメント（意図と異なる目標追求）を検出し、その分布を補正するための解析手法が提示されている。さらに、[Nanda 23, Okawa 23] では、学習過程における新たな能力や行動傾向の出現をトレースし、予期せぬ挙動の発現を未然に防ぐ枠組みの研究が進められている。ほかにも、敵対的攻撃の防御に応用されている。例えば、画像中に文字列を埋め込むことで視覚言語モデルを誤認識させる

Typographic Attack に対して、攻撃に脆弱な回路や特徴量を特定し除去することで防御する手法が提案されている [Huang 25, Hufe 25]。

5.2 効率的なモデル設計

MI を活用した解釈性研究は、LLM の動作原理を解明し、より効率的なモデル設計や高性能アーキテクチャの提案につながる可能性がある [Olah 20a]。実際、状態空間モデル Mamba [Gu 24] は、MI 研究で発見された帰納ヘッドの知見を設計に取り入れている。帰納ヘッドは LLM において系列情報の一般化に重要な役割を果たす回路であり、Mamba の設計は MI の分析結果が新たなアーキテクチャに直接活かされた代表的な事例といえる。さらに、MI を応用して特定の回路や特徴量を制御する新たなファインチューニング手法 [Cho 25a] も提案されている。

6. 課 題 と 限 界

MI は急速に発展している一方で、依然として多くの課題を抱えている。本章では、特にスケーラビリティ・自動化・原理的限界という観点から主要な論点を整理する。

6.1 スケーラビリティと自動化

MI の多くの研究は小規模モデルや単純タスクを対象としており [Elhage 22], 大規模モデルや実用的タスクへの適用は依然として十分に検証されていない。この課題を受けて、OpenAI や Anthropic などの研究機関では大規模 SAE の開発を進めており、スケーラブルな MI の実現を模索している [Gao 25, Templeton 24]。また、[Lieberum 23] は、小規模モデルで得られた回路構造が大規模モデルには必ずしも一般化しないことを指摘し、スケーラビリティの限界を示している。

さらに、モデル規模の拡大に伴い、人手による回路分析や介入は現実的でなくなりつつあり、自動化された MI への関心が高まっている。実際、回路検出や解釈の自動化を目指す研究が進展しており [Conmy 23], 将来的には MI の大規模化と統合的理解の両立が期待されている。

6.2 原理的限界

MI のようなボトムアップ的手法によって、複雑化するモデルを完全に理解できるのかという根本的な限界も指摘されている。例えば、AlphaZero はチェスの概念を人間とは異なる方法で獲得していると報告されており [McGrath 22], モデル内部の知識体系（オントロジー）が人間のそれと乖離する可能性が示唆されている。[Hendrycks 22] は、モデル規模の拡大に伴ってこのオントロジーの乖離が拡大しうることを警告している。

さらに、SAE を用いた場合でも依然として「暗黒物質 (Dark Matter)」と呼ばれる未解明の活性領域が残存することが報告されており [Engels 25b], 現状の MI のアプ

^{*5} 注意すべき点として、ここで用いる Ablation という用語は、モデル開発研究において各モジュールの有効性評価のために行われる Ablation Study を指すものではない。本稿における Ablation とは、モデルの順伝播における因果的計算経路から特定の構成要素を取り除く操作を意味する。

ローチによる深層学習モデルの完全な理解には原理的な限界がありうることを示唆している。加えて、トランスフォーマーのように文脈依存的に挙動を変化させるモデルでは、モデルの重み単体の解析のみでは不十分であり、動的相互作用の観点を考慮する必要がある。実際、主要な注意ヘッドを無効化しても他のヘッドが機能を代替する「Hydra Effect」が報告されており [McGrath 23], このような冗長で動的な機構の理解が今後の MI の鍵になると指摘されている [Mueller 24].

7. 展 望

今後の MI 研究においては、標準化、学際的融合、新技術への拡張が重要となる。本章では、これら三つの観点から MI の発展方向を展望する。

7.1 標準化とベンチマーク

MI 研究の大きな課題の一つは、解釈性を定量的に評価し、標準化することである。そもそも「解釈可能性」は明確に定義しにくい概念であり、これを数量的に扱うこと自体が容易ではない。近年、SAE を対象としたベンチマークとして SAEbench [Karvonen 25] が公開され、[Gao 25, Minegishi 25] に見られるように、MI 手法を多角的に比較・評価する枠組みの整備が進みつつある。また、MI のための包括的ベンチマーク MIB [Mueller 25] も提案されており、これらは MI 研究の基盤的な共通指標を確立する試みと位置づけられる。このような標準化は、研究間の再現性と客観的比較を可能にし、MI 分野の体系的発展に寄与することが期待される。加えて、実運用や産業応用を見据えた場合には、評価コストやモデル更新に対する頑健性、説明結果の監査可能性といった観点も重要となる。特に MIB [Mueller 25] に見られるように、単に解釈可能な特徴量が存在するかどうかだけでなく、それらがモデル出力に因果的な影響を与えているかを検証するベンチマーク設計は、信頼性が要求される応用において本質的である。

7.2 学際的な融合

MI は、「回路」という概念や、脳部位の損傷研究に類似する「アブレーション」手法を用いることからわかるように、もともと神経科学的アプローチに着想を得ている [Lindsay 23, Olah 20b, Vilas 24]. 神経科学の知見をさらに取り入れることで、時間構造を考慮した SAE の目的関数の改良 [Lubana 25] など、理論や手法の精緻化が進んでいる。また、物理学的視点からニューラルネットワークを実験的に解析する試み [Allen-Zhu 25, Kunin 21] や、SAE を病理学領域に応用する研究 [Le 24, Wang 26], さらに学習済みネットワークの内部構造の解釈を通じて新たな科学的発見を目指す取り組み [Cranmer 24] など、学際的な融合が進展している。これらは、MI を

AI 安全やモデル理解の枠を超えて、科学的探究の手法として位置づける可能性を示している。

7.3 新しい技術パラダイムへの対応

深層学習の発展に伴い、MI 研究も新しい技術パラダイムに対応していく必要がある。本サーベイでは主にトランスフォーマー言語モデルの解釈性技術を扱ったが、トランスフォーマーアーキテクチャを視覚ドメインに応用した視覚トランスフォーマー (ViT) [Dosovitskiy 21] の解釈に対しても Logit Lens や SAE といった代表的な手法が応用されている [Joseph 25b, Joseph 25a, Takatsuki 25] (図 2)。さらに、トランスフォーマー型のマルチモーダル言語モデル (MLLM) に対しても、同様の手法を適用する研究が盛んに行われている [Lin 25, Liu* 25]。一方で、テスト時計算 [Snell 24] や Reasoning [Zhang 25] のような推論時計算手法についてはまだ研究例が少なく、MI 的観点からの理解や分析が十分に進んでいない。さらに、ロボティクスやエージェントなどの分野においても、内部表現や行動生成の解釈に焦点を当てた MI 的アプローチは限定的である。今後、これらの新領域への拡張が MI 研究の重要な課題となるだろう。

8. ま と め

Mechanistic Interpretability (MI) はニューラルネットワーク内部の因果構造を理解しようとする研究潮流として国際的に注目を集めているが、日本語で体系的に議論された資料はこれまで存在していなかった。そこで本論文では、MI について日本語で初めて体系的に整理することを試みた。

既存の英語サーベイでは、歴史的背景、安全性との関係、技術的手法、未解決問題といった個別の観点からの整理が主であった。本稿はそれらの議論を踏まえつつ、MI の定義の明確化および用語の標準化を行い、既存の解釈可能性研究との関係を整理するとともに、産業動向や実用化の文脈を含めて横断的に位置づけた。

MI は依然として発展途上の研究領域であるが、モデル内部の因果構造を理解することを通じて、安全性・信頼性の向上や、新たなモデル設計に寄与する可能性を有している。本稿が、国内における研究基盤の整備と共通理解の形成に資するとともに、今後の理論的深化および実践的展開の一助となることを期待する。

◇ 参 考 文 献 ◇

- [Adebayo 18] Adebayo, J., Gilmer, J., Muelly, M., Goodfellow, I., Hardt, M., and Kim, B.: Sanity checks for saliency maps, *Advances in Neural Information Processing Systems*, Vol. 31, pp. 9525–9536 (2018)
- [Aharon 06] Aharon, M., Elad, M., and Bruckstein, A.: K-SVD: an algorithm for designing overcomplete dictionaries for sparse representation, *IEEE Transactions on Signal Processing*, Vol. 54, No. 11,

- pp. 4311–4322 (2006)
- [Alain 17] Alain, G., et al.: Understanding intermediate layers using linear classifier probes, in *the 5th International Conference on Learning Representations, ICLR 2017, Workshop Track Proceedings* (2017)
- [Allen-Zhu 25] Allen-Zhu, Z. and Li, Y.: Physics of language models: part 1, learning hierarchical language structures, *Transactions on Machine Learning Research* (2025)
- [Ameisen 25] Ameisen, E., et al.: Circuit tracing: revealing computational graphs in language models, *Transformer Circuits Thread* (2025)
- [Ansuini 19] Ansuini, A., Laio, A., Macke, J. H., and Zoccolan, D.: Intrinsic dimension of data representations in deep neural networks, *Advances in Neural Information Processing Systems*, Vol. 32, pp. 6111–6122 (2019)
- [Anthropic] Anthropic: Transformer circuits thread — transformer-circuits.pub, <https://transformer-circuits.pub/>: [Accessed 01-02-2025]
- [Anthropic 25a] Anthropic: System card: claude opus 4.5, Technical report, Anthropic (2025), [Accessed 10-02-2026]
- [Anthropic 25b] Anthropic: System card: claude sonnet 4.5, Technical report, Anthropic (2025), [Accessed 10-02-2026]
- [Anthropic 26] Anthropic: System card: claude opus 4.6, Technical report, Anthropic (2026), [Accessed 10-02-2026]
- [apollo] Apollo research, <https://www.apolloresearch.ai/research> [Accessed 30-10-2025]
- [Basu 24a] Basu, S., Grayson, M., Morrison, C., Nushi, B., Feizi, S., and Massiceti, D.: Understanding information storage and transfer in multi-modal large language models, in *the 38th Annual Conference on Neural Information Processing Systems* (2024)
- [Basu 24b] Basu, S., Zhao, N., Morariu, V. I., Feizi, S., and Manjunatha, V.: Localizing and editing knowledge in text-to-image generative models, in *the 12th International Conference on Learning Representations* (2024)
- [Belinkov 17] Belinkov, Y., Durrani, N., Dalvi, F., Sajjad, H., and Glass, J.: What do neural machine translation models learn about morphology?, in Barzilay, R. and Kan, M.-Y. eds., *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (volume 1: Long Papers)*, pp. 861–872 (2017)
- [Belrose 23] Belrose, N., et al.: Eliciting latent predictions from transformers with the tuned lens, *arXiv preprint arXiv:2303.08112* (2023)
- [Bereska 24] Bereska, L. and Gavves, S.: Mechanistic interpretability for AI safety - a review, *Transactions on Machine Learning Research* (2024)
- [Bibal 22] Bibal, A., et al.: Is attention explanation? an introduction to the debate, in Muresan, S., Nakov, P., and Villavicencio, A. eds., *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (volume 1: Long Papers)*, pp. 3889–3900 (2022)
- [Bills 23] Bills, S., et al.: Language models can explain neurons in language models, <https://openaipublic.blob.core.windows.net/neuron-explainer/paper/index.html> (2023)
- [Bilodeau 22] Bilodeau, B., Jaques, N., Koh, P. W., and Kim, B.: Impossibility theorems for feature attribution, *arXiv [cs.LG]* (2022)
- [Black 22] Black, S., et al.: Interpreting neural networks through the polytope lens, *arXiv [cs.LG]* (2022)
- [Braun 25] Braun, D., Bushnaq, L., Heimersheim, S., Mendel, J., and Sharkey, L.: Interpretability in parameter space: minimizing mechanistic description length with attribution-based parameter decomposition, *arXiv preprint arXiv:2501.14926* (2025)
- [Bricken 23] Bricken, T., et al.: Towards monosemanticity: decomposing language models with dictionary learning, *Transformer Circuits Thread* (2023)
- [Bussmann 24] Bussmann, B., Leask, P., and Nanda, N.: Batchtopk sparse autoencoders, in *Neurips 2024 Workshop on Scientific Methods for Understanding Deep Learning* (2024)
- [Cammarata 20] Cammarata, N., et al.: Thread: circuits, *Distill* (2020)
- [Cammarata 21] Cammarata, N., et al.: Curve circuits, *Distill* (2021)
- [Cho 25a] Cho, H., Luo, P., Kato, M., Kaenbyou, R., and Inoue, N.: Mechanistic fine-tuning for in-context learning, in Belinkov, Y., Mueller, A., Kim, N., Mohebbi, H., Chen, H., Arad, D., and Sarti, G. eds., *Proceedings of the 8th BlackboxNLP Workshop: Analyzing and Interpreting Neural Networks for NLP*, pp. 330–357 (2025)
- [Cho 25b] Cho, H., Yang, H., Kurkoski, B. M., and Inoue, N.: Binary autoencoder for mechanistic interpretability of large language models, *arXiv preprint arXiv:2509.20997* (2025)
- [Cho 26] Cho, H., Yang, H., Minegishi, G., and Inoue, N.: Mechanism of task-oriented information removal in in-context learning, in *the 14th International Conference on Learning Representations* (2026)
- [conjecture] Conjecture — conjecture.dev, <https://www.conjecture.dev/> [Accessed 01-02-2025]
- [Conmy 23] Conmy, A., Mavor-Parker, A. N., Lynch, A., Heimersheim, S., and Garriga-Alonso, A.: Towards automated circuit discovery for mechanistic interpretability, in *37th Conference on Neural Information Processing Systems* (2023)
- [Cranmer 24] Cranmer, M.: The next great scientific theory is hiding inside a neural network, <https://www.simonsfoundation.org/event/the-next-great-scientific-theory-is-hiding-inside-a-neural-network/> (2024), [Accessed 25-01-2025]
- [Craver 25] Craver, C. F.: Mechanistic explanation, in *Open Encyclopedia of Cognitive Science* (2025)
- [Dosovitskiy 21] Dosovitskiy, A., et al.: An image is worth 16x16 words: transformers for image recognition at scale, in *International Conference on Learning Representations* (2021)
- [Dunefsky 24] Dunefsky, J., Chlenski, P., and Nanda, N.: Transcoders find interpretable llm feature circuits, *Advances in Neural Information Processing Systems*, Vol. 37, pp. 24375–24410 (2024)
- [Elazar 21] Elazar, Y., Ravfogel, S., Jacovi, A., and Goldberg, Y.: Amnesic probing: behavioral explanation with amnesic counterfactuals, *Transactions of the Association for Computational Linguistics*, Vol. 9, pp. 160–175 (2021)
- [Elhage 21] Elhage, N., et al.: A mathematical framework for transformer circuits, *Transformer Circuits Thread* (2021)
- [Elhage 22] Elhage, N., et al.: Toy models of superposition, *Transformer Circuits Thread* (2022)
- [Engels 25a] Engels, J., Michaud, E. J., Liao, I., Gurnee, W., and Tegmark, M.: Not all language model features are one-dimensionally linear, in *the 13th International Conference on Learning Representations* (2025)
- [Engels 25b] Engels, J., Smith, L. R., and Tegmark, M.: Decomposing the dark matter of sparse autoencoders, *Transactions on Machine Learning Research* (2025)
- [Ethayarajh 19] Ethayarajh, K.: How contextual are contextualized word representations? comparing the geometry of BERT, ELMo, and GPT-2 embeddings, in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pp. 55–65 (2019)
- [Gao 25] Gao, L., et al.: Scaling and evaluating sparse autoencoders, in *the 13th International Conference on Learning Representations* (2025)
- [Ghandeharioun 24] Ghandeharioun, A., Caciularu, A., Pearce, A., Dixon, L., and Geva, M.: Patchscopes: a unifying framework for inspecting hidden representations of language models, in *41st International Conference on Machine Learning* (2024)
- [Ghorbani 20] Ghorbani, A. and Zou, J. Y.: Neuron shapley: discovering the responsible neurons, *Advances in Neural Information Processing Systems*, Vol. 33, pp. 5922–5932 (2020)
- [Giulianelli 18] Giulianelli, M., Harding, J., Mohnert, F., Hupkes, D., and Zuidema, W.: Under the hood: using diagnostic classifiers to investigate and improve how language models track agreement information, in Linzen, T., Chrupala, G., and Alishahi, A. eds., *Proceedings of the 2018 EMNLP Workshop blackboxNLP: Analyzing and Interpreting Neural Networks for NLP*, pp. 240–248 (2018)
- [Goldowsky-Dill 23] Goldowsky-Dill, N., et al.: Localizing model behavior with path patching, *arXiv [cs.LG]* (2023)
- [goodfireGo] Goodfire AI — goodfire.ai, <https://www.goodfire.ai/> [Accessed 01-02-2025]

- [Gu 24] Gu, A. and Dao, T.: Mamba: linear-time sequence modeling with selective state spaces, in *the 1st Conference on Language Modeling* (2024)
- [Gurnee 24] Gurnee, W., et al.: Universal neurons in GPT2 language models, *Transactions on Machine Learning Research* (2024)
- [Hanna 23] Hanna, M., Liu, O., and Variengien, A.: How does GPT-2 compute greater-than?: interpreting mathematical abilities in a pre-trained language model, in *the 37th Conference on Neural Information Processing Systems* (2023)
- [Heimersheim 24] Heimersheim, S. and Nanda, N.: How to use and interpret activation patching, *arXiv preprint arXiv:2404.15255* (2024)
- [Hendrycks 22] Hendrycks, D., et al.: X-risk analysis for AI research, *arXiv preprint arXiv:2206.05862* (2022)
- [Hewitt 19] Hewitt, J. and Liang, P.: Designing and interpreting probes with control tasks, in Inui, K., Jiang, J., Ng, V., and Wan, X. eds., *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pp. 2733–2743 (2019)
- [Hoogland 23] Hoogland, et al.: Towards developmental interpretability — AI alignment forum — alignmentforum.org, <https://www.alignmentforum.org/posts/TjaeCWvLZtEDAS5Ex/towards-developmental-interpretability> (2023), [Accessed 02-02-2025]
- [Hsu 25] Hsu, A. R., et al.: Efficient automated circuit discovery in transformers using contextual decomposition, in *the 13th International Conference on Learning Representations* (2025)
- [Huang 25] Huang, R. and Wang, S.: Steering LLMs’ behavior with concept activation vectors, in *the 4th Blogpost Track at ICLR 2025* (2025)
- [Huben 24a] Huben, R., Cunningham, H., Smith, L. R., Ewart, A., and Sharkey, L.: Sparse autoencoders find highly interpretable features in language models, in *the 12th International Conference on Learning Representations* (2024)
- [Huben 24b] Huben, R., Cunningham, H., Smith, L. R., Ewart, A., and Sharkey, L.: Sparse autoencoders find highly interpretable features in language models, in *the 12th International Conference on Learning Representations* (2024)
- [Hufe 25] Hufe, L., Venhoff, C., Dreyer, M., Lapuschkin, S., and Samek, W.: Towards mechanistic defenses against typographic attacks in CLIP, in *Mechanistic Interpretability Workshop at Neurips 2025* (2025)
- [Huh 24] Huh, M., Cheung, B., Wang, T., and Isola, P.: Position: the platonic representation hypothesis, in *the 41st International Conference on Machine Learning* (2024)
- [Jain 19] Jain, S. and Wallace, B. C.: Attention is not explanation, in Burstein, J., Doran, C., and Solorio, T. eds., *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (long and Short Papers)*, pp. 3543–3556 (2019)
- [Joseph 25a] Joseph, S., et al.: Prisma: an open source toolkit for mechanistic interpretability in vision and video, *arXiv preprint arXiv:2504.19475* (2025)
- [Joseph 25b] Joseph, S., et al.: Steering CLIP’s vision transformer with sparse autoencoders, *arXiv preprint arXiv:2504.08729* (2025)
- [Kadlčík 25] Kadlčík, M., Štefánik, M., Mickus, T., Kuchař, J., and Spiegel, M.: Pre-trained language models learn remarkably accurate representations of numbers, in Christodoulopoulos, C., Chakraborty, T., Rose, C., and Peng, V. eds., *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, pp. 26705–26714 (2025)
- [Kantamneni 25] Kantamneni, S., Engels, J., Rajamanoharan, S., Tegmark, M., and Nanda, N.: Are sparse autoencoders useful? a case study in sparse probing, in *the 42nd International Conference on Machine Learning* (2025)
- [Karpathy 15] Karpathy, A., Johnson, J., and Fei-Fei, L.: Visualizing and understanding recurrent networks, *arXiv preprint arXiv:1506.02078* (2015)
- [Karvonen 25] Karvonen, A., et al.: SAEBench: a comprehensive benchmark for sparse autoencoders in language model interpretability, in *the 42nd International Conference on Machine Learning* (2025)
- [Kataiwa 25] Kataiwa, T., Hakaze, C., and Ohki, T.: Measuring intrinsic dimension of token embeddings, *arXiv preprint arXiv:2503.02142* (2025)
- [Kindermans 19] Kindermans, P.-J., et al.: *The (un)reliability of saliency methods*, pp. 267–280, Springer, Cham (2019)
- [Kirsanov 25] Kirsanov, A., Chou, C.-N., Cho, K., and Chung, S.: The geometry of prompting: unveiling distinct mechanisms of task adaptation in language models, in *Findings of the Association for Computational Linguistics: NAACL 2025*, pp. 1855–1888 (2025)
- [Klabunde 25a] Klabunde, M., Schumacher, T., Strohmaier, M., and Lemmerich, F.: Similarity of neural network models: a survey of functional and representational measures, *ACM Computing Surveys*, Vol. 57, No. 9, pp. 1–52 (2025)
- [Klabunde 25b] Klabunde, M., Wald, T., Schumacher, T., Maier-Hein, K., Strohmaier, M., and Lemmerich, F.: Resi: a comprehensive benchmark for representational similarity measures, in *the 13th International Conference on Learning Representations* (2025)
- [Kobayashi 20] Kobayashi, G., Kuribayashi, T., Yokoi, S., and Inui, K.: Attention is not only a weight: analyzing transformers with vector norms, in Webber, B., Cohn, T., He, Y., and Liu, Y. eds., *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 7057–7075 (2020)
- [Kornblith 19] Kornblith, S., Norouzi, M., Lee, H., and Hinton, G.: Similarity of neural network representations revisited, in *International Conference on Machine Learning*, pp. 3519–3529 PMIR (2019)
- [Kunin 21] Kunin, D., et al.: Neural mechanics: symmetry and broken conservation laws in deep learning dynamics, in *the 9th International Conference on Learning Representations, ICLR 2021, Virtual Event, Austria, May 3-7, 2021* (2021)
- [Le 24] Le, N. M., et al.: Learning biologically relevant features in a pathology foundation model using sparse autoencoders, in *Advances in Medical Foundation Models: Explainability, Robustness, Security, and Beyond* (2024)
- [Leask 25] Leask, P., et al.: Sparse autoencoders do not find canonical units of analysis, in *the 13th International Conference on Learning Representations* (2025)
- [Li 16] Li, J., Monroe, W., and Jurafsky, D.: Understanding neural networks through representation erasure, *arXiv preprint arXiv:1612.08220* (2016)
- [Li 23] Li, K., Patel, O., Viégas, F., Pfister, H., and Wattenberg, M.: Inference-time intervention: eliciting truthful answers from a language model, in *the 37th Conference on Neural Information Processing Systems* (2023)
- [Li 24] Li, M. and Janson, L.: Optimal ablation for interpretability, *Advances in Neural Information Processing Systems*, Vol. 37, pp. 109233–109282 (2024)
- [Lieberum 23] Lieberum, T., et al.: Does circuit analysis interpretability scale? evidence from multiple choice capabilities in chimchilla, *arXiv preprint arXiv:2307.09458* (2023)
- [Lin 25] Lin, Z., Basu, S., Beigi, M., Manjunatha, V., Rossi, R. A., Wang, Z., Zhou, Y., Balasubramanian, S., Zarei, A., Rezaei, K., et al.: A survey on mechanistic interpretability for multi-modal foundation models, *arXiv preprint arXiv:2502.17516* (2025)
- [Lindsay 23] Lindsay, G. W. and Bau, D.: Testing methods of neural systems understanding, *Cognitive Systems Research*, Vol. 82, No. 101156, p. 101156 (2023)
- [Lindsey 24] Lindsey, J., Templeton, A., Marcus, J., Conerly, T., Batson, J., and Olah, C.: Sparse crosscoders for cross-layer features and model diffing, *Transformer Circuits Thread*, pp. 3982–3992 (2024)
- [Lindsey 25] Lindsey, J., et al.: On the biology of a large language model, *Transformer Circuits Thread* (2025)
- [Liu* 25] Liu*, Y., Zhang*, Y., and Yeung-Levy, S.: Mechanistic interpretability meets vision language models: insights and limitations, in *ICLR Blogposts 2025* (2025)
- [Lou 25] Lou, H., Li, C., Ji, J., and Yang, Y.: SAE-V: interpreting multimodal models for enhanced alignment, in *42nd International Conference on Machine Learning* (2025)
- [Lubana 25] Lubana, E. S., et al.: Priors in time: missing inductive

- biases for language model interpretability, *arXiv [cs.LG]* (2025)
- [Lundberg 17] Lundberg, S. M. and Lee, S.: A unified approach to interpreting model predictions, in *Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017, December 4-9, 2017*, pp. 4765–4774 (2017)
- [Marks 25] Marks, S., Rager, C., Michaud, E. J., Belinkov, Y., Bau, D., and Mueller, A.: Sparse feature circuits: discovering and editing interpretable causal graphs in language models, in *the 13th International Conference on Learning Representations* (2025)
- [Marr 10] Marr, D.: *Vision: a computational investigation into the human representation and processing of visual information* (2010)
- [McGrath 22] McGrath, et al.: Acquisition of chess knowledge in alphazero, *Proceedings of the National Academy of Sciences*, Vol. 119, No. 47 (2022)
- [McGrath 23] McGrath, T., Rahtz, M., Kramar, J., Mikulik, V., and Legg, S.: The hydra effect: Emergent self-repair in language model computations, *arXiv preprint arXiv:2307.15771* (2023)
- [Meng 22] Meng, K., Bau, D., Andonian, A., and Belinkov, Y.: Locating and editing factual associations in GPT, *Advances in Neural Information Processing Systems*, Vol. 35, pp. 17359–17372 (2022)
- [Merullo 24] Merullo, J., Eickhoff, C., and Pavlick, E.: Circuit component reuse across tasks in transformer language models, in *the 12th International Conference on Learning Representations* (2024)
- [Minegishi 25] Minegishi, G., et al.: Rethinking evaluation of sparse autoencoders through the representation of polysemous words, in *the 13th International Conference on Learning Representations* (2025)
- [Modell 25] Modell, A., Rubin-Delanchy, P., and Whiteley, N.: The origins of representation manifolds in large language models, *arXiv preprint arXiv:2505.18235* (2025)
- [Mueller 24] Mueller, A.: Missed causes and ambiguous effects: counterfactuals pose challenges for interpreting neural networks, in *ICML 2024 Workshop on Mechanistic Interpretability* (2024)
- [Mueller 25] Mueller, A., et al.: MIB: a mechanistic interpretability benchmark, in *the 42nd International Conference on Machine Learning* (2025)
- [Nanda 23] Nanda, N., et al.: Progress measures for grokking via mechanistic interpretability, in *the 11th International Conference on Learning Representations, ICLR 2023* (2023)
- [Nanda 24] Nanda, N., et al.: [Summary] progress update #1 from the GDM mech interp team — AI alignment forum — alignmentforum.org, <https://www.alignmentforum.org/s/AtTzjoDm8q3DbdT8Z/p/HPAr8k74mW4ivCvCu> (2024), [Accessed 01-02-2025]
- [Neo 25] Neo, C., Ong, L., Torr, P., Geva, M., Krueger, D., and Barez, F.: Towards interpreting visual information processing in vision-language models, in *the 13th International Conference on Learning Representations* (2025)
- [Nguyen 19] Nguyen, A., Yosinski, J., and Clune, J.: Understanding neural networks via feature visualization: a survey, in *Explainable AI: Interpreting, Explaining and Visualizing Deep Learning*, pp. 55–76 (2019)
- [nostalgebr 20] Interpreting GPT: the logit lens — AI alignment forum — alignmentforum.org, <https://www.alignmentforum.org/posts/AcKRB8wDpdaN6v6ru/interpreting-gpt-the-logit-lens> (2020), [Accessed 09-02-2025]
- [Okawa 23] Okawa, M., Lubana, E. S., Dick, R. P., and Tanaka, H.: Compositional abilities emerge multiplicatively: exploring diffusion models on a synthetic task, in *37th Conference on Neural Information Processing Systems* (2023)
- [Olah 17] Olah, C., et al.: Feature visualization, *Distill*, Vol. 2, No. 11 (2017)
- [Olah 20a] Olah, C., et al.: Naturally occurring equivariance in neural networks, *Distill* (2020)
- [Olah 20b] Olah, C., et al.: Zoom in: an introduction to circuits, *Distill* (2020)
- [Olah 22] Olah, C.: Mechanistic interpretability, variables, and the importance of interpretable bases — transformer-circuits.pub, <https://transformer-circuits.pub/2022/mech-interp-essay/index.html> (2022), [Accessed 01-02-2025]
- [Olsson 22] Olsson, C., et al.: In-context learning and induction heads, *Transformer Circuits Thread* (2022)
- [Park 24a] Park, K., et al.: The linear representation hypothesis and the geometry of large language models, in *Proceedings of the 41st International Conference on Machine Learning*, Vol. 235 of *Proceedings of Machine Learning Research*, pp. 39643–39666 (2024)
- [Park 24b] Park, P. S., Goldstein, S., O’Gara, A., Chen, M., and Hendrycks, D.: AI deception: a survey of examples, risks, and potential solutions, *Patterns*, Vol. 5, No. 5 (2024)
- [Paulo 25] Paulo, G. S., Mallen, A. T., Juang, C., and Belrose, N.: Automatically interpreting millions of features in large language models, in *42nd International Conference on Machine Learning* (2025)
- [Rai 24] Rai, D., Zhou, Y., Feng, S., Saparov, A., and Yao, Z.: A practical review of mechanistic interpretability for transformer-based language models, *arXiv preprint arXiv:2407.02646* (2024)
- [Rajamanoharan 24a] Rajamanoharan, S., et al.: Improving sparse decomposition of language model activations with gated sparse autoencoders, in *the 38th Annual Conference on Neural Information Processing Systems* (2024)
- [Rajamanoharan 24b] Rajamanoharan, S., et al.: Jumping ahead: improving reconstruction fidelity with jumprelu sparse autoencoders, *arXiv preprint arXiv:2407.14435* (2024)
- [Ribeiro 16] Ribeiro, M. T., Singh, S., and Guestrin, C.: “Why should i trust you?”, in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 1135–1144 (2016)
- [Roy 07] Roy, O. and Vetterli, M.: The effective rank: a measure of effective dimensionality, in *2007 15th European Signal Processing Conference*, pp. 606–610 (2007)
- [Schubert 21] Schubert, L., et al.: High/low frequency detectors, *Distill*, Vol. 6, No. 1 (2021)
- [Selvaraju 17] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., and Batra, D.: Grad-CAM: visual explanations from deep networks via gradient-based localization, in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)* (2017)
- [Serrano 19] Serrano, S. and Smith, N. A.: Is attention interpretable?, in Korhonen, A., Traum, D., and Márquez, L. eds., *Proceedings of the 37th Annual Meeting of the Association for Computational Linguistics*, pp. 2931–2951 (2019)
- [Sharkey 25] Sharkey, L., et al.: Open problems in mechanistic interpretability, *Transactions on Machine Learning Research* (2025)
- [Shi 16] Shi, X., Padhi, I., and Knight, K.: Does string-based neural MT learn source syntax?, in Su, J., Duh, K., and Carreras, X. eds., *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, pp. 1526–1534 (2016)
- [Shi 25] Shi, W., et al.: Route sparse autoencoder to interpret large language models, *arXiv preprint arXiv:2503.08200* (2025)
- [Shu 25] Shu, D., et al.: A survey on sparse autoencoders: interpreting the internal mechanisms of large language models, in Christodoulopoulos, C., Chakraborty, T., Rose, C., and Peng, V. eds., *Findings of the Association for Computational Linguistics: EMNLP 2025*, pp. 1690–1712 (2025)
- [Simonyan 13] Simonyan, K., et al.: Deep inside convolutional networks: visualising image classification models and saliency maps, *ArXiv preprint arXiv:1312.6034* (2013)
- [Snell 24] Snell, C., et al.: Scaling LLM test-time compute optimally can be more effective than scaling model parameters, *ArXiv preprint arXiv:2408.03314* (2024)
- [Stolfo 25] Stolfo, A., Wu, B. P., and Sachan, M.: Antipodal pairing and mechanistic signals in dense SAE latents, in *ICLR 2025 Workshop on Building Trust in Language Models and Applications* (2025)
- [Sun 25] Sun, X., et al.: Dense SAE latents are features, not bugs, in *the 39th Annual Conference on Neural Information Processing Systems* (2025)
- [Sundararajan 17] Sundararajan, M., et al.: Axiomatic attribution for deep networks, in *Proceedings of the 34th International Conference on Machine Learning, ICML 2017*, Vol. 70 of *Proceedings of Machine Learning Research*, pp. 3319–3328 (2017)
- [Surkov 25] Surkov, V., et al.: One-step is enough: sparse autoencoders for text-to-image diffusion models, in *the 39th Annual Conference on Neural Information Processing Systems* (2025)
- [Syed 23] Syed, A., Rager, C., and Conmy, A.: Attribution patch-

ing outperforms automated circuit discovery, in *the 7th Blackboxnlp Workshop* (2023)

- [Takatsuki 25] Takatsuki, R., Joseph, S., Fujisawa, I., and Kanai, R.: Decoding vision transformers: the diffusion steering lens, *2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, pp. 4819–4824 (2025)
- [Templeton 24] Templeton, A., et al.: Scaling monosemanticity: extracting interpretable features from claude 3 sonnet, *Transformer Circuits Thread* (2024)
- [Tenney 19] Tenney, I., Das, D., and Pavlick, E.: BERT rediscovers the classical NLP pipeline, in Korhonen, A., Traum, D., and Màrquez, L. eds., *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pp. 4593–4601 (2019)
- [tilde] Tilde, <https://www.tildersearch.com/> [Accessed 30-10-2025]
- [Turner 23] Turner, A. M., et al.: Steering language models with activation engineering, *arXiv preprint arXiv:2308.10248* (2023)
- [Vilas 24] Vilas, M. G., Adolff, F., Poeppel, D., and Roig, G.: Position: an inner interpretability framework for AI inspired by lessons from cognitive neuroscience, in *International Conference on Machine Learning*, pp. 49506–49522 (2024)
- [Voita 19] Voita, E., Talbot, D., Moiseev, F., Sennrich, R., and Titov, I.: Analyzing multi-head self-attention: specialized heads do the heavy lifting, the rest can be pruned, in Korhonen, A., Traum, D., and Màrquez, L. eds., *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pp. 5797–5808 (2019)
- [Wang 23] Wang, K. R., et al.: Interpretability in the wild: a circuit for indirect object identification in GPT-2 small, in *the 11th International Conference on Learning Representations, (ICLR 2023)* (2023)
- [Wang 25] Wang, J., et al.: Towards universality: studying mechanistic similarity across language model architectures, in *the 13th International Conference on Learning Representations* (2025)
- [Wang 26] Wang, N., et al.: Using interpretability to identify a novel class of biomarkers for alzheimer’s detection (2026), Goodfire and Prima Mente collaboration
- [Watanabe 09] Watanabe, S.: *Algebraic geometry and statistical learning theory*, Vol. 25 (2009)
- [Wiegrefe 19] Wiegrefe, S. and Pinter, Y.: Attention is not not explanation, in Inui, K., Jiang, J., Ng, V., and Wan, X. eds., *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pp. 11–20 (2019)
- [Wiegrefe 24] Wiegrefe, S. and Saphra, N.: Mechanistic?, in *the 7th Blackboxnlp Workshop* (2024)
- [Yang 25] Yang, H., Cho, H., Zhong, Y., and Inoue, N.: Unifying attention heads and task vectors via hidden state geometry in in-context learning, in *the 39th Annual Conference on Neural Information Processing Systems* (2025)
- [Zhang 25] Zhang, D., et al.: From system 1 to system 2: a survey of reasoning large language models, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, pp. 1–20 (2025)
- [Zheng 25] Zheng, Z., et al.: Attention heads of large language models, *Patterns*, Vol. 6, No. 2, p. 101176 (2025)
- [Zou 23] Zou, A., et al.: Representation engineering: a top-down approach to AI transparency, *ArXiv preprint arXiv:2310.01405* (2023)

〔担当委員：武石 直也〕

2025 年 10 月 30 日 受理

—— 著 者 紹 介 ——



青木 洸士郎

2026 年早稲田大学基幹理工学部情報理工学科卒業。現在、同大学院基幹理工学研究科情報理工・情報通信専攻在学中。大規模言語モデルなどのニューラルネットワークの解釈可能性に関する研究に従事。



高槻 瞭大

2023 年東京大学工学部システム創成学科卒業。現在、サセックス大学意識科学センター博士 1 年（情報学）。また、2024 年より一般社団法人 AI アライメントネットワークにて研究フェロー。深層学習モデルの解釈性手法を応用した意識研究に従事。



峰岸 剛基(学生会員)

2023 年東京大学工学部機械工学科卒業。現在、同大学院工学系研究科技術経営戦略学専攻博士 2 年。深層学習モデルの内部解釈の研究に従事。



趙 羽風(学生会員)

理化学研究所基礎科学特別研究員、東北大学研究員。北京理工大学にて 2021 年に化学の学士号、2023 年にソフトウェア工学の修士号、北陸先端科学技術大学院大学にて 2026 年に博士号を取得。博士（情報科学）。ニューラルネットワークの解明に関する研究に従事。